

UNIVERSIDAD DE COSTA RICA

IE-0624 LABORATORIO DE MICROCONTROLADORES

Laboratorio # 5

Freddy Zúñiga Cerdas

A45967

Profesor

MARCO VILLALTA FALLAS

July 2, 2023

1 Introducción

En el presente trabajo se creó un programa para HAR (Human Activity Recognition), para lo cual se utilizó la placa Arduino NANO 33 BLE y la plataforma Edge Impulse. El programa utiliza machine learning para reconocer 4 tipos diferentes de gestos:

- arriba_abajo: movimientos de arriba a abajo.
- circular: es un movimiento circular.
- estático: en este caso la placa permanece inmóvil.
- punch: es un movimiento horizontal hacia adelante y atrás.

La posición relativa de la placa para estos movimientos se explicará más adelante.

El programa debe ser capaz de reconocer el movimiento que uno está realizando con la placa y asignarle probabilidades a cada uno de los 4 movimientos para, además debe realizarse una comunicación serial con la computadora para mostrar en una terminal los datos que infiere el programa.

El repositorio de Github se puede consultar en la siguiente dirección [link del repositorio github](#)

2 Nota Teórica

En este apartado se mostrarán algunas características del microcontrolador así como una breve introducción a HAR (Human Activity Recognition).

2.1 Placa Arduino NANO 33 BLE

Se utilizó la placa Arduino NANO 33 BLE para el presente laboratorio.

2.1.1 Características Generales

El Arduino NANO 33 BLE cuenta con un microcontrolador nRF52840 con las siguientes características:

- CPU: ARM Cortex-M4 a 64 MHz con FPU, 32-bit, 1MB Flash, 256kb SRAM.
- Blue tooth 5, IEEE 802.15.4-2006, 2.4 GHz
- ARM TrustZone Cryptocell 310 security subsystem, secure boot
- USB 2.0, QSPI, SPI
- 48 GPIOs
- 12-bit, ADC con 8 canales
- 64 comparadores de nivel, 15 del tipo low-power
- Sensor de temperatura
- 4x 4-canales PWM
- Perifericos de audio: I2S, PDM
- 5x 32-bit timers
- 4x SPI maestros/3x SPI esclavos
- 2x I2C
- 2x UART
- decodificador de cuadratura (QDEC)
- 3x RTC

2.1.2 Diagrama de Bloques

En la Figura 1 se muestra en detalle el diagrama de bloques del microcontrolador.

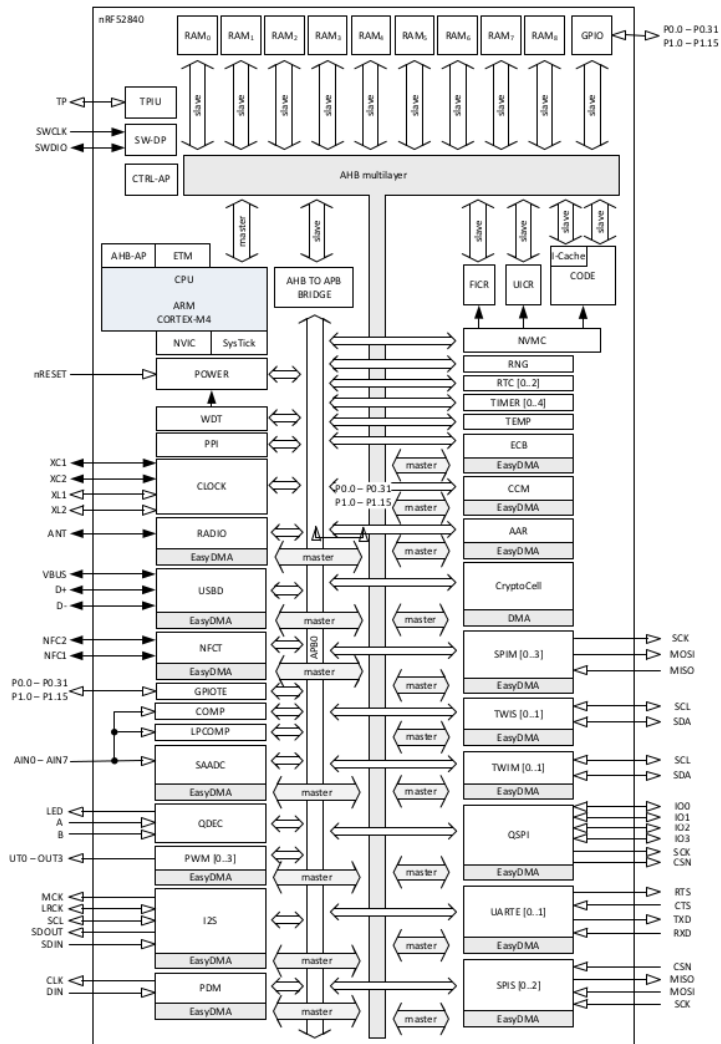


Figura 1: Diagrama de Bloques del nRF52840 [1]

2.1.3 Diagrama de Pines

En la Figura 2 se muestra el diagrama de pines de la placa.

2.1.4 Características Eléctricas

En la Figura 3 se muestran las características eléctricas del microcontrolador.




Figura 2: Diagrama de Pines del Arduino NANO 33 BLE [2]

1 The Board

As all Nano form factor boards, Nano 33 BLE Sense does not have a battery charger but can be powered through USB or headers.

NOTE: Arduino Nano 33 BLE Sense only supports 3.3V I/Os and is **NOT** 5V tolerant so please make sure you are not directly connecting 5V signals to this board or it will be damaged. Also, as opposed to Arduino Nano boards that support 5V operation, the 5V pin does NOT supply voltage but is rather connected, through a jumper, to the USB power input.

1.1 Ratings

1.1.1 Recommended Operating Conditions

Symbol	Description	Min	Max
	Conservative thermal limits for the whole board:	-40 °C (40 °F)	85°C (185 °F)

1.2 Power Consumption

Symbol	Description	Min	Typ	Max	Unit
PBL	Power consumption with busy loop		TBC		mW
PLP	Power consumption in low power mode		TBC		mW
PMAX	Maximum Power Consumption		TBC		mW

Figura 3: Características Eléctricas del Arduino NANO 33 BLE [2]

2.2 Human Activity Recognition (HAR)

La Human Activity Recognition (HAR) o Reconocimiento de Actividad Humana es un campo de estudio que se enfoca en desarrollar algoritmos y técnicas para identificar y clasificar actividades realizadas por seres humanos utilizando datos capturados de diferentes sensores. El objetivo es detectar y reconocer automáticamente las acciones o actividades que una persona está llevando a cabo [3].

El HAR tiene aplicaciones en una amplia gama de áreas, como la salud y el bienestar, la seguridad, la monitorización del rendimiento deportivo, la interacción hombre-máquina y la detección de caídas, entre otros. Se basa en la idea de que las actividades humanas generan patrones y características específicas en los datos de los sensores, como acelerómetros, giroscopios, magnetómetros o incluso cámaras y micrófonos [4].

Para realizar el reconocimiento de actividad humana, se utilizan diversas técnicas de aprendizaje automático y procesamiento de señales, como algoritmos de clasificación, redes neuronales, SVM (Support Vector Machines), árboles de decisión, entre otros. Estos algoritmos se entrenan con conjuntos de datos etiquetados que contienen ejemplos de diferentes actividades para que puedan aprender a reconocer y clasificar nuevas actividades basadas en características extraídas de los datos de los sensores [5].

El objetivo final del HAR es permitir que las máquinas comprendan e interpreten las acciones y

actividades humanas de manera más inteligente, lo que puede llevar a mejoras en la eficiencia, la seguridad, la comodidad y la calidad de vida en diversos contextos y aplicaciones.

2.3 Machine Learning Aplicado a HAR

El Machine Learning aplicado al Reconocimiento de Actividad Humana (HAR) es un campo de investigación en el que se utilizan algoritmos y técnicas de aprendizaje automático para identificar y clasificar actividades realizadas por seres humanos a partir de datos capturados de sensores.

En el contexto del HAR, el Machine Learning se utiliza para extraer patrones y características significativas de los datos de sensores, como acelerómetros, giroscopios y magnetómetros. Estos datos son procesados y utilizados para entrenar modelos que pueden reconocer y clasificar diferentes actividades humanas, como caminar, correr, levantar objetos, subir escaleras, entre otras [6].

El enfoque típico implica la recolección de un conjunto de datos etiquetados que contienen ejemplos de diferentes actividades realizadas por varias personas. Estos datos se utilizan para entrenar algoritmos de aprendizaje automático, como clasificadores, redes neuronales o SVM (Support Vector Machines), con el objetivo de que los modelos aprendan a reconocer patrones y características específicas asociadas a cada actividad [7].

2.4 Firmware

El firmware fue realizado utilizando la herramienta Edge Impulse, en la cual se creo la arquitectura de las redes neuronales para resolver el problema, ver Figura 4, en este caso como suele ser muy común en machine learning los valores de neuronas y otros parámetros de interés suelen obtenerse en mayor o menor medida con prueba y error, este fue el caso en el cual se agregaron capas dropout para evitar el sobreajuste y los valores de las neuronas fueron cambiados a potencias pares de 2 como suelen recomendar algunos expertos, los valores se fueron calibrando hasta obtener los valores finales que resolvían de buena manera el problema.

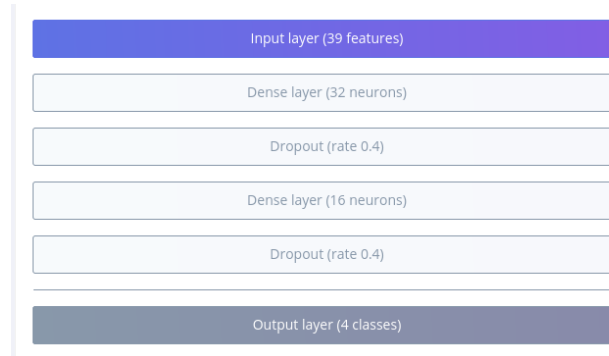


Figura 4: Arquitectura de la red neuronal [imagen propia]

Para obtener el resultado final se necesito pasar por varias etapas, etapas que fueron menos complejas gracias a la herramienta Edge Impulse.

2.4.1 Etapa 1: Obtención de los datos para el entrenamiento

La etapa de entrenamiento fue muy fácil de llevar acabo gracias a edge-impulse-cli y el script suministrado por edge impulse (Edge Impulse Firmware) para quemar un programa de obtención de datos directamente en el Arduino Nano 33 BLE, link con información. En principio se tomaron datos teniendo en mente 3 tipos de movimientos, pero debido a que no se agregó el movimiento estático que es por decirlo así un movimiento por efecto se agregó posteriormente, de tal manera que se cuentan con 4 movimientos, los cuales se muestran de manera más clara, para conocer la orientación en que se realizaron dichos movimientos en la Figura 5.

Para la etapa de entrenamiento se realizaron 4 minutos de toma de datos por movimiento y al rededor de 1 minuto para la etapa de validación.

2.4.2 Etapa 2: Ajuste de parámetros

En esta etapa se fueron ajustando algunos de los parámetros (número de neuronas, valor dropout, número de epochs) para obtener un modelo fiable, por lo que se compilaba y se observaban los resultados, se cambiaban poco a poco los parámetros y se repetía, en este caso se usaban los datos de validación pero también se fueron probando nuevos datos.

2.4.3 Etapa 3: Cargado del programa en la placa

En la última etapa se cargó el programa generado por Edge Impulse en la placa y se empezó a probar los resultados, esta etapa también tuvo que ver con la Etapa 2 pues se tuvieron que reajustar algunas cosas, se probaba el modelo en la placa y se volvían a ajustar los parámetros y se cargaba el nuevo programa, se repitió este proceso unas 4 veces hasta que los resultados fueron satisfactorios.




Figura 5: Movimientos y orientación realizados con la placa Arduino Nano 33 BLE [imagen propia]

2.5 Componentes Electrónicos Utilizados

El único componente utilizado fue la placa Arduino Nano 33 BLE, la cual fue comprada debido a la escases de esta placa en la bodega, el precio total de la placa fue de: 91 dólares, al rededor de 50 mil colones.

3 Análisis de Resultados

Para la evaluación de esta parte se creo el siguiente video, en el cual se muestra el funcionamiento del programa en una terminal: primer video demostrativo.

En dicho video se muestra tanto la salida en la terminal de la computadora como el movimiento hecho en la placa Arduino Nano 33 BLE, para mostrar que en efecto se logra una gran precisión a la hora de predecir el movimiento y catalogarlo en una de las 4 categorías.

El siguiente video es de menor calidad grabado con el celular donde trato de mostrar tanto el movimiento de la placa como el resultado en la terminal: segundo video demostrativo.

4 Conclusiones y Recomendaciones

En el presente trabajo se utilizó la placa de desarrollo Arduino Nano 33 BLE para realizar HAR utilizando machine learning, dicha tarea se realizó de manera correcta según los resultados vistos en el video, por lo que se puede concluir que el laboratorio cumplió con los items solicitados.

4.1 Recomendaciones

Una buena estructura o plan de trabajo es fundamental para realizar este tipo de trabajos, y esto fue mucho más simple gracias a la plataforma Edge Impulse en la cual se ahorra una gran cantidad de trabajo y se obtienen resultados de mucha calidad, como se suele decir no se trata de reinventar la rueda, si existen este tipo de plataformas usarlas es una gran ayuda.

Bibliografía

- [1] Nordic Semiconductor, *nRF52840: Product Specification v1.1*, 2019.
- [2] Arduino AG, *Arduino NANO 33 BLE Sense: Product Reference Manual*, 2022.
- [3] C. Jobanputra, J. Bavishi, and N. Doshi, “Human activity recognition: A survey,” *Procedia Computer Science*, vol. 155, pp. 698–703, 2019.
- [4] A. Bulling, U. Blanke, and B. Schiele, “A tutorial on human activity recognition using body-worn inertial sensors,” *ACM Computing Surveys (CSUR)*, vol. 46, no. 3, pp. 1–33, 2014.
- [5] L. Bao and S. S. Intille, “Activity recognition from user-annotated acceleration data,” in *International conference on pervasive computing*, pp. 1–17, Springer, 2004.
- [6] N. Gupta, S. K. Gupta, R. K. Pathak, V. Jain, P. Rashidi, and J. S. Suri, “Human activity recognition in artificial intelligence framework: A narrative review,” *Artificial intelligence review*, vol. 55, no. 6, pp. 4755–4808, 2022.
- [7] I. M. Nasir, M. Raza, J. H. Shah, M. A. Khan, and A. Rehman, “Human action recognition using machine learning in uncontrolled environment,” in *2021 1st International Conference on Artificial Intelligence and Data Analytics (CAIDA)*, pp. 182–187, IEEE, 2021.